Analítica Computacional Para la Toma de Decisiones

Proyecto 1

Analítica de Datos Saber 11 Córdoba

Abraham Bohórquez
Samuel Arbeláez
Lucas Muñoz

Usuario Principal

Gobernador de Córdoba
Erasmo Zuleta

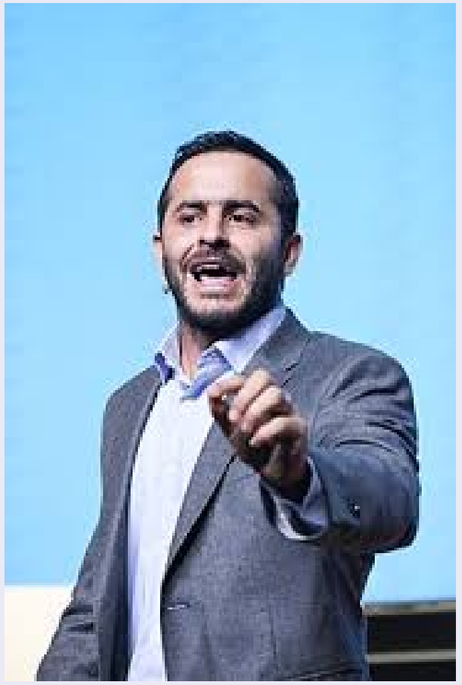

Limpieza en AWS

- Importar los datos a AWS S3. Y a traves de athena filtrarlos para mostrar el departamento de Córdoba.
- En athena se realiza una consulta en SQL para extraer los datos de este departamento que se guardan en un bucket de salida.
- Se exportan los datos del bucket de salida en formato CSV.

Limpieza en Python

01.

Se importan los datos a python con codificación "utf-8-sig", se codifican las fechas en formato date-time, y se eliminan los duplicados.

02.

Analizar las variables categoricas. Corregir la falta de tildes en municipios duplicados (Corregir monteria a montería por ejemplo). La base de datos presenta caracteres con tildes faltantes “¿” en la categoria “cole_nombre_sede”

03.

Cada analista realiza una eliminación propia de datos faltantes. Eliminando unicamente datos que falten en sus categorias pertinentes. Se agregan las columnas de estimación de fecha en la cual se tomo el ICFES, y edad de la persona que tomo el ICFES.

Brechas territoriales e institucionales.

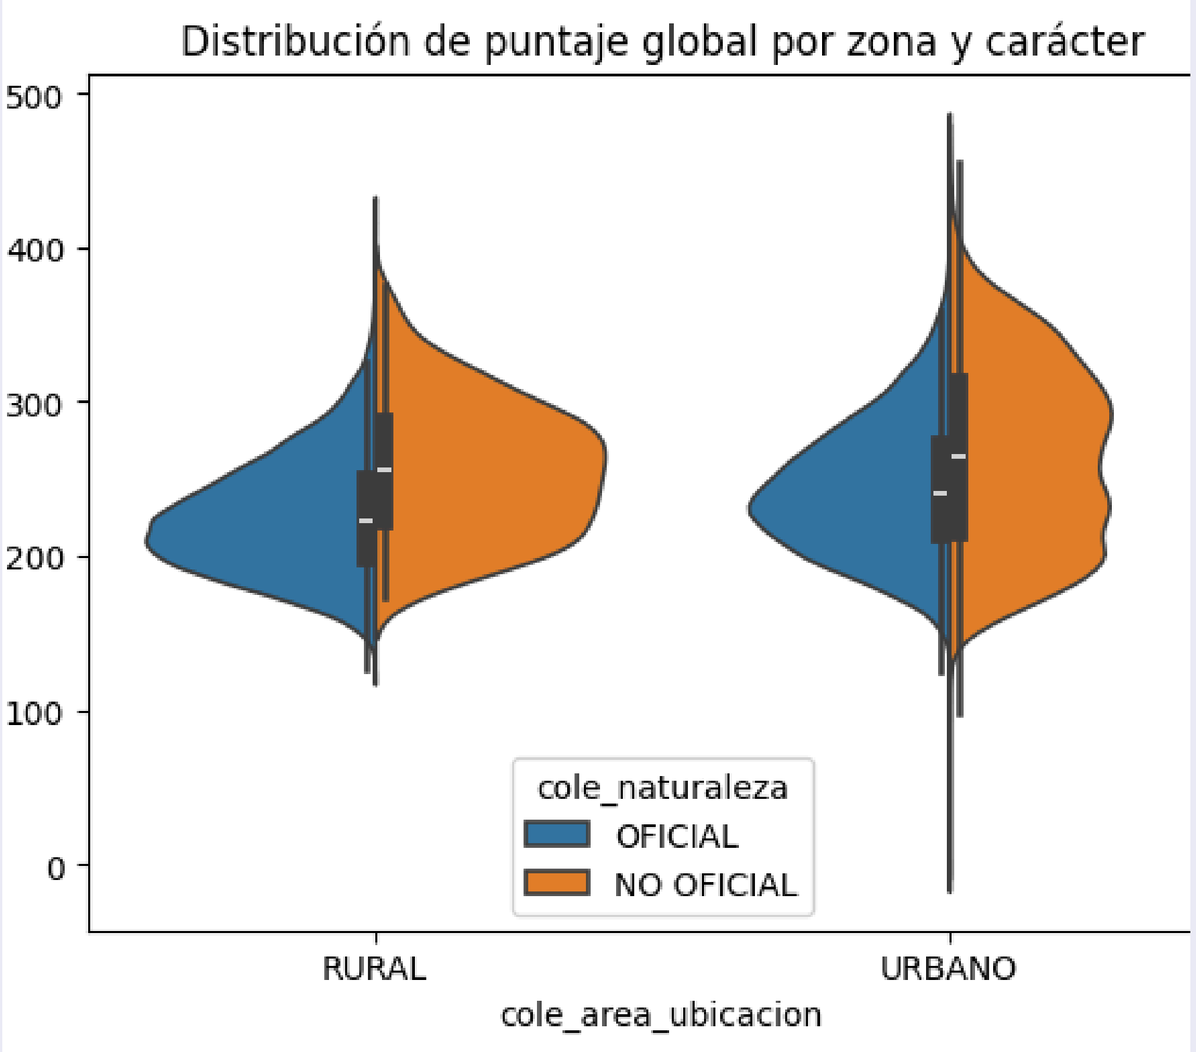

- Se observa un desplazamiento de la distribución urbana hacia puntajes más altos, lo que indica mejor desempeño relativo frente a la zona rural.

- Las medianas y cuantiles intermedios difieren entre grupos, confirmando una brecha en la tendencia central.

- La densidad en zona rural se concentra en rangos más bajos, mientras que en zona urbana se concentra en niveles medio–altos.

- La separación entre distribuciones se mantiene a lo largo de buena parte del rango de puntajes, lo que sugiere una brecha estructural y no aislada.

- También se evidencia diferenciación por naturaleza del establecimiento, con desplazamientos consistentes entre distribuciones.

Brechas territoriales e institucionales.

H_0: μ_oficial = μ_no-oficial

$H_1 : \neg H_0$

Se rechaza H_0.

Existe diferencia estadísticamente significativa en el puntaje promedio según la naturaleza del establecimiento.

H_0: μ_rural = μ_urbano

$H_1 : \neg H_0$

Se rechaza H_0.

Existe diferencia estadísticamente significativa en el puntaje promedio entre zona rural y urbana.

Influencia del Nivel Socio-Económico

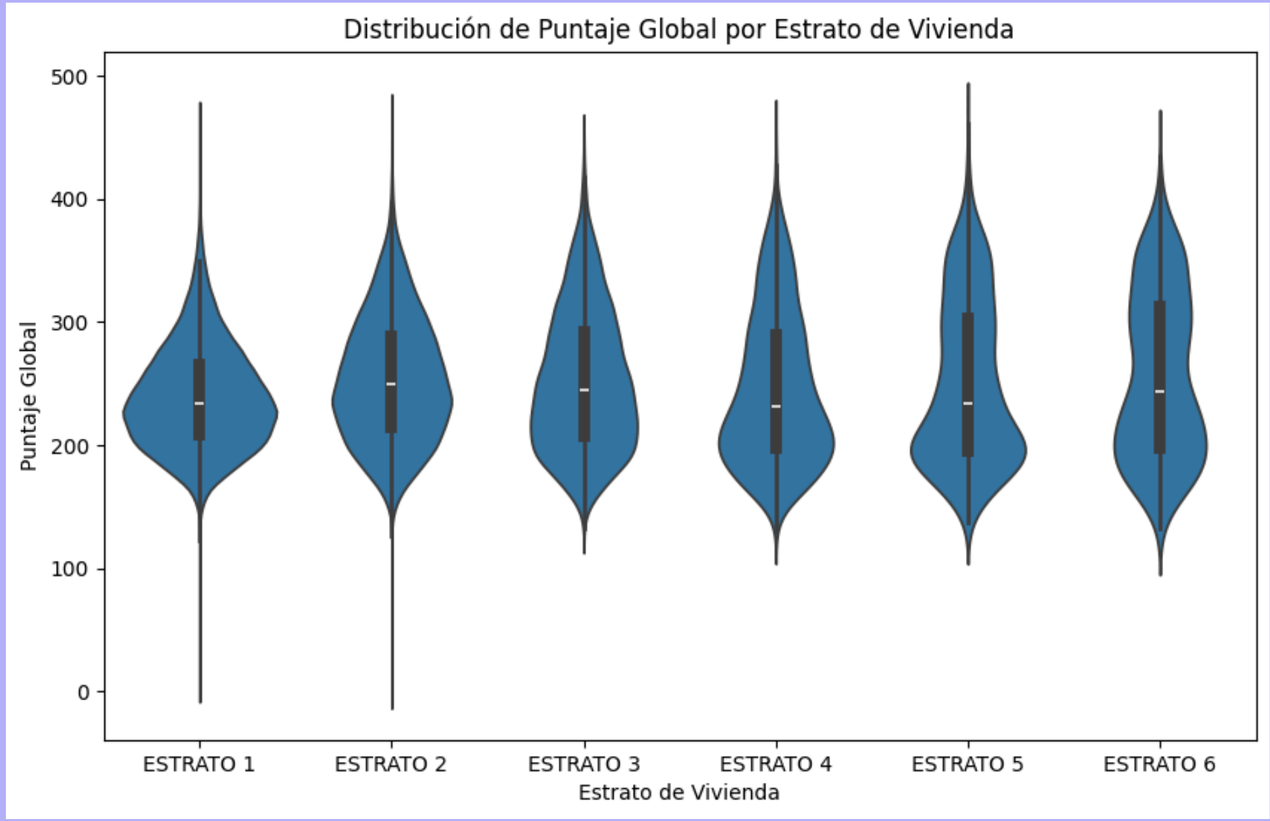

ANOVA

$H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5 = \mu_6$

$H_1 : \neg H_0$

Existen diferencias significativas entre los puntajes promedio según estrato.

Tukey HSD

$H_0: \mu_i = \mu_j$

$H_1: \mu_i \neq \mu_j$

- Estrato 1 difiere de todos los demás.
- Estratos 2 y 3 no difieren entre sí.
- Estratos 5 y 6 no difieren entre sí.

Evidencia de agrupamiento socioeconómico.

Influencia del Nivel Socio-Económico

Mayor asociación con puntaje global:

- Educación madre: 0.39
- Educación padre: 0.38
- Índice de recursos: 0.33
- Estrato: 0.10

El capital educativo del hogar es el factor más asociado al desempeño.

El estrato influye poco de manera directa por si solo.

Educación de madre y padre están fuertemente correlacionadas (0.67).

La brecha no es solo económica, es principalmente educativa y estructural del hogar.

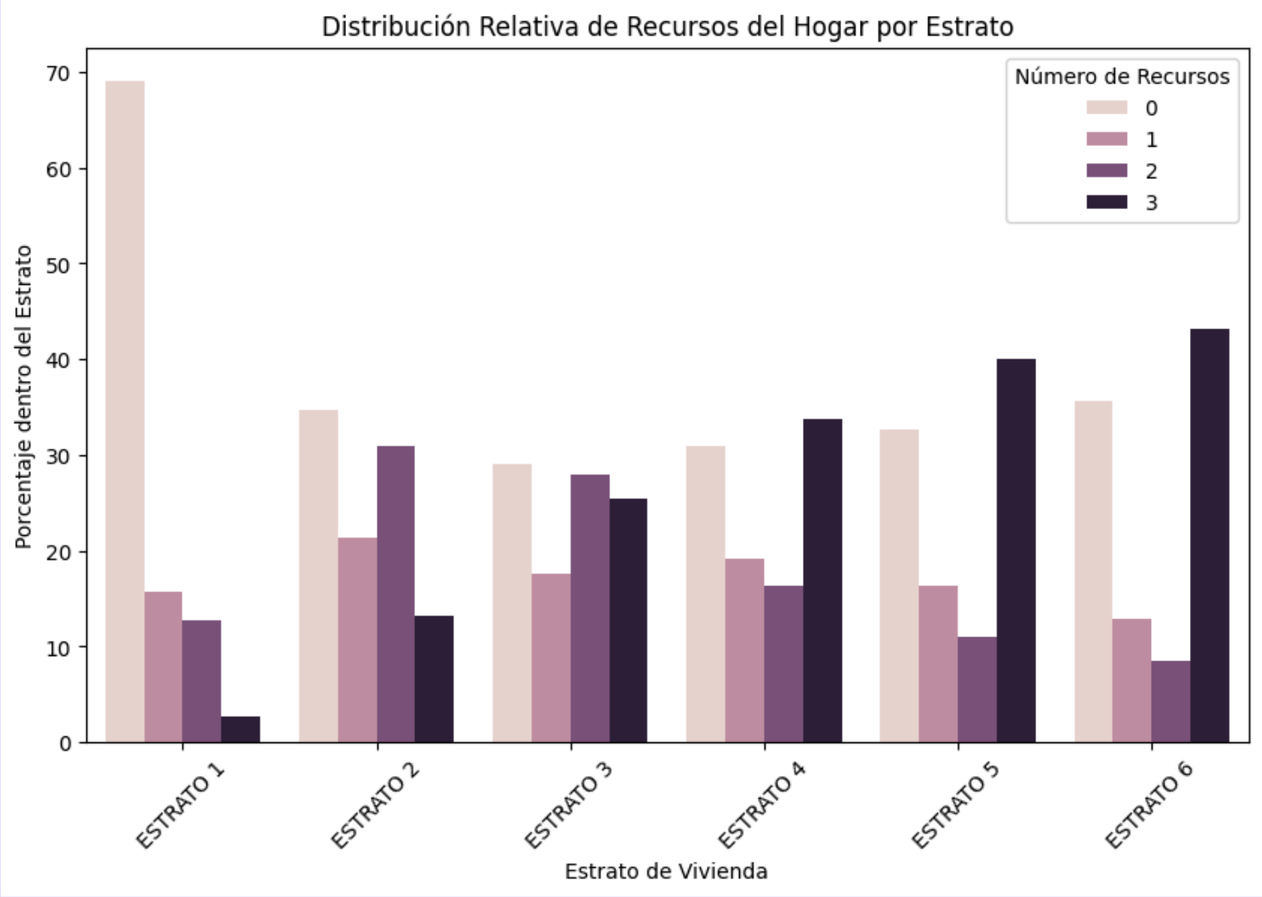

Atraso en trayectos academicos por edad

- Se observa el histograma de la edad de personas que toman el ICFES en Cordoba

- A partir del scatter plot se puede ver a primera vista que entre mayor edad, peor es el rendimiento según el puntaje global del ICFES.

- Para probar estos resultados se realiza una regresión lineal y se prueba la significancia de β_1. En este caso

$$\beta_1 = -6.0193$$

$$H_0: \beta_1 = 0$$

$$H1: \beta_1 \neq 0$$

$$\text{p-value} < 0.001$$

- Se demuestra estadisticamente que a mayor edad, el puntaje global en el ICFES tiende a disminuir.

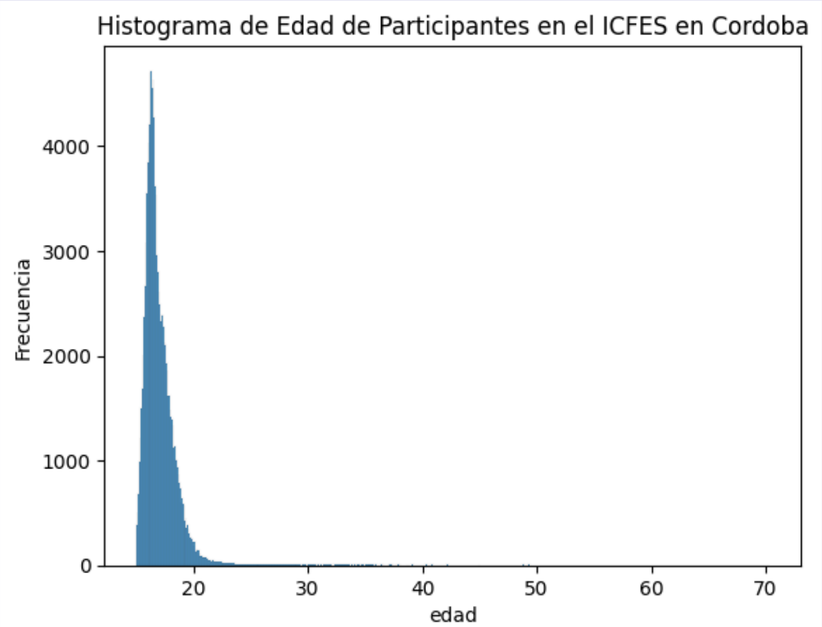

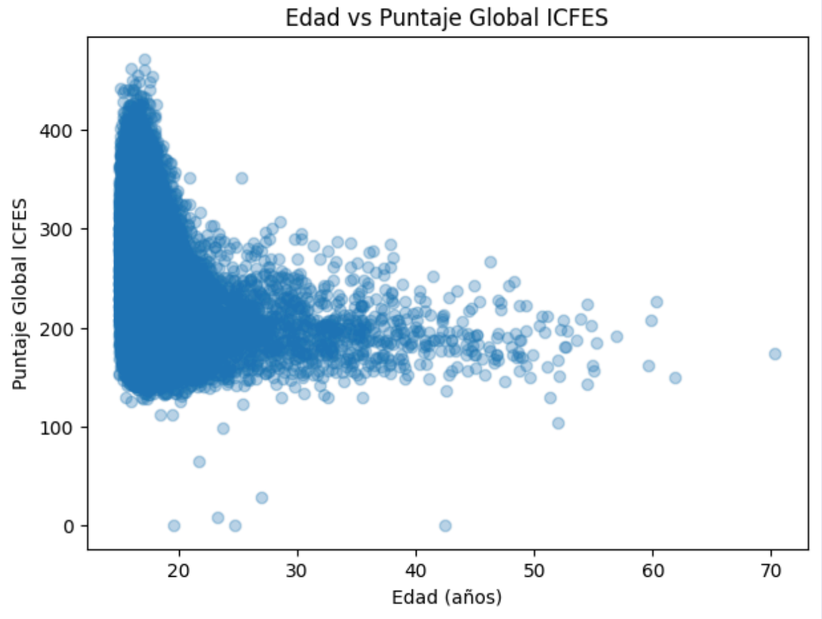

Atraso en trayectos academicos por edad

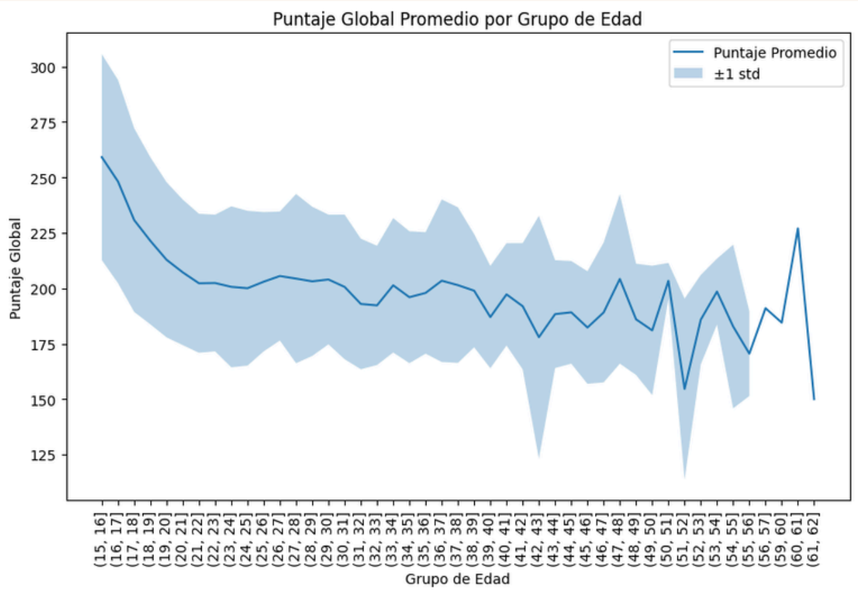

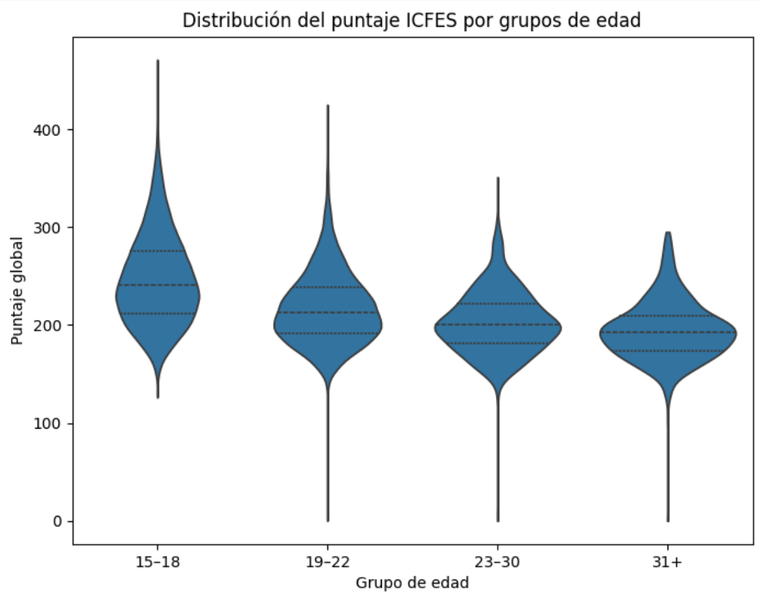

- Se aplican dos metodos distintos para visualizar la disminución en puntaje mediante aumenta la edad.

- Mean binning: Se separan las edades por años y se observa la media y desviación estandar en cada uno de estos. Se puede observar que mediante aumenta la edad, disminuye el promedio de puntaje obtenido.

- Violin-plot: Se separan los datos en 4 grupos de edad y se realiza un violin-plot. Se puede observar que entre mayor edad, menor es la media del puntaje del ICFES.

- Violin-plot: Mayor varianza en grupos con menor edad ya que hay más personas en estos grupos que toman el ICFES.

- Enfocar sus esfuerzos en campañas de refuerzo a la educación básica y de bachillerato en la población de adultos garantizando una preparación adecuada.

Muchas Gracias